

Equivalencia entre el método Ada-Boosting y Forward Stageway Additive Model

Andrés Nieto Guadarrama

Lema:

Encontrar la clasificación óptima mediante el método de *Ada Boosting* equivale a implementar el modelo aditivo con la función de costo

$$L(y, f(x)) = e^{-yf(x)}.$$

Demostración

Observar que, para cada paso m , el método del modelo aditivo busca al clasificador G_m y al parámetro β_m tales que:

$$(\beta_m, G_m) = \min_{\beta, G} \left\{ \sum_{i=1}^N e^{-y_i(f_{m-1}(x_i) + \beta G(x_i))} \right\} = \min_{\beta, G} \left\{ \sum_{i=1}^N e^{-y_i f_{m-1}(x_i)} e^{-y_i \beta G(x_i)} \right\} = \min_{\beta, G} \left\{ \sum_{i=1}^N w_i^{(m)} e^{-y_i \beta G(x_i)} \right\}$$

con $w_i^{(m)} = e^{-y_i f_{m-1}(x_i)} > 0$ independiente de G y β . Más aún, partiendo la suma anterior tenemos que

$$\sum_{i=1}^N w_i^{(m)} e^{-y_i \beta G(x_i)} = \sum_{\{i: y_i = G(x_i)\}} w_i^{(m)} e^{-\beta} + \sum_{\{i: y_i \neq G(x_i)\}} w_i^{(m)} e^{\beta} = \sum_{i=1}^N w_i^{(m)} e^{-\beta} - \sum_{\{i: y_i \neq G(x_i)\}} w_i^{(m)} e^{-\beta} + \sum_{\{i: y_i \neq G(x_i)\}} w_i^{(m)} e^{\beta}$$

con lo cual,

$$\sum_{i=1}^N w_i^{(m)} e^{-y_i \beta G(x_i)} = \sum_{i=1}^N w_i^{(m)} e^{-\beta} + (e^{\beta} - e^{-\beta}) \sum_{\{i: y_i \neq G(x_i)\}} w_i^{(m)} = \sum_{i=1}^N w_i^{(m)} e^{-\beta} + (e^{\beta} - e^{-\beta}) \sum_{i=1}^N w_i^{(m)} - \sum_{\{i: y_i = G(x_i)\}} w_i^{(m)} (e^{\beta} - e^{-\beta})$$

Dado que el único elemento de la suma que se ve afectado por la función clasificadora es

$\sum_{i=1}^N w_i^{(m)} 1_{\{y_i \neq G(x_i)\}}$, tenemos que para cada paso m

$$G_m = \min_G \left\{ \sum_{i=1}^N w_i^{(m)} 1_{\{y_i \neq G(x_i)\}} \right\}.$$

Notemos que a partir de éstos cálculos ya se consiguió el clasificador G_m y los pesos $w_i^{(m)}$ requeridos como primer paso en el algoritmo *Ada Boosting M1*.

Por otro lado, sustituyendo a G por G_m en la función objetivo, podemos notar que las sumas $\sum_{i=1}^N w_i^{(m)}$ y $\sum_{i=1}^N w_i^{(m)} 1_{\{y_i \neq G(x_i)\}}$ no dependen de β , por lo que β_m se encuentra minimizando la función en \mathbb{R} :

$$g(\beta) = Ae^{-\beta} + B(e^{\beta} - e^{-\beta}), = (A - B)e^{-\beta} + Be^{\beta}$$

con $A = \sum_{i=1}^N w_i^{(m)}$ y $B = \sum_{i=1}^N w_i^{(m)} 1_{\{y_i \neq G_m(x_i)\}}$

Por condiciones de primer orden, β_m debe cumplir que:

$$0 = g'(\beta_m) = (B - A)e^{-\beta_m} + Be^{\beta_m} = \frac{1}{e^{\beta_m}}((B - A) + Be^{2\beta_m}),$$

esto es,

$$\beta_m = \frac{1}{2} \ln \left(\frac{A - B}{B} \right) = \frac{1}{2} \ln \left(\frac{\sum_{i=1}^N w_i^{(m)} 1_{\{y_i = G_m(x_i)\}}}{\sum_{i=1}^N w_i^{(m)} 1_{\{y_i \neq G_m(x_i)\}}} \right) = \frac{1}{2} \ln \left(\frac{1 - err_m}{err_m} \right)$$

donde $err_m = \frac{B}{A}$ es el error de predicción de la función clasificadora G_m .

Una vez encontradas β_m y G_m , el siguiente paso del modelo aditivo nos lleva a actualizar las funciones f_m de manera que:

$$f_m = f_{m-1} + G_m \beta_m.$$

Sin embargo, por la forma en que definimos los pesos w_i^m , tenemos que para el siguiente paso:

$$w_i^{m+1} = e^{-y_i f_m(x_i)} = e^{-y_i f_{m-1}(x_i)} e^{-y_i G_m(x_i) \beta_m} = w_i^m e^{-y_i G_m(x_i) \beta_m}$$

Más aún, dado que $-y_i G_m(x_i) = -1$ si $y_i = G_m(x_i)$ y $-y_i G_m(x_i) = 1$ si $y_i \neq G_m(x_i)$, podemos escribir a $-y_i G_m(x_i)$ como

$$-y_i G_m(x_i) = 21_{\{y_i \neq G_m(x_i)\}} - 1$$

Con lo cual,

$$w_i^{m+1} = w_i^m e^{2\beta_m 1_{\{y_i \neq G_m(x_i)\}}} e^{-\beta_m}$$

Finalmente, observar que el factor $e^{-\beta_m}$ afecta a todas las w_i^{m+1} para toda $i = 1, \dots, N$, por lo que puede omitirse. Por lo tanto, se obtuvieron los mismos valores para β , G y w_i^m que si se hubiera seguido el algoritmo de *AdaBoosting M1*■